# 個案研究
# 巨量資料分析有多可靠？

當今的公司正面對來自社群媒體、搜尋、感應器，以及傳統來源的大量資料。據估計，全世界每天產生 2,500 萬億的位元組資料。我們期盼能透過巨量資料分析來改善所有組織的決策和經營績效，但這也帶來巨大的挑戰。

Amazon、YouTube 和 Spotify 等企業正透過分析所蒐集到的客戶興趣與購物歷史巨量資料來提供數百萬筆個人化推薦，進而讓公司蓬勃發展。許多線上服務也正運用巨量資料分析來幫助消費者尋找汽車、電腦、手機方案、服裝、機票、飯店住宿等商品或服務的最低價。巨量資料分析也為運動賽事(請參閱本章的開章個案)、教育、科學、醫療保健和執法帶來好處。

透過分析病患、醫療保健提供者以及處方籤和治療方式有效性等數十億筆資料，讓英國國民保健署 (NHS) 節省約 5.81 億英磅 (約 7.84 億美元)。資料存放在 Oracle Exadata Database Machine，可以快速分析大量資料 (請參閱本章對分析平台的討論)。NHS 利用巨量資料分析的成果來建立儀表板，找出一次服用 10 種藥物的患者以及哪些患者正在服用過量抗生素。大量編譯癌症用藥和治療結果數據並串連患者的資訊，已經幫助 NHS 找出更有效的治療方案。

紐約市分析與犯罪相關的所有資料來試著降低犯罪率。它的 CompStat 犯罪地圖計畫彙整市區 76 個轄區的報案或投訴、逮捕、法院傳喚的資料庫，每週呈現各個轄區、巡邏區以及整個市區的犯罪與逮捕資訊。CompStat 數據可以顯示犯罪和逮捕地點以及犯罪熱點等相關訊息，幫助轄區指揮官快速找出樣式和趨勢，並針對最需要的地方佈署警察。犯罪活動的巨量資料也協助紐約市犯罪策略部門 (Crime Strategies Unit) 將嚴重違法者積極起訴。醫療保健公司正分析巨量資料，針對慢性病和常見病的治療找出最有效和最省錢的方式，並提供個人化的護理建議給病人。

巨量資料分析有一定的侷限性。許多公司急於啟動巨量資料分析計畫，而不是先為它設定企業目標或建立衡量成功與否的關鍵績效指標。在一堆資料中打滾並不意味著你正在蒐集正確的資訊，或人們將做出更明智的決策。巨量資料分析的專家認為，有太多公司被巨量資料分析的美麗願景所誘惑而跳入巨量資料分析，但沒有搞清楚該努力的目標方向。他們開始蒐集大量但沒有明確目標的資料，也不知道如何透過巨量資料分析來實現其企業目標或解決所遭遇到的問題。組織也不會從未正確清理、組織、管理的巨量資料中獲益 —— 記得資料品質很重要。

某件事可以測量不意味著就應該測量。例如，假設一家大公司想要衡量網站流量與 Twitter 上被提及次數的關係，因而建立了數位儀表板來不斷顯示這個訊息。過去，公司的銷售成果大多來自於參加貿易展與研討會，把 Twitter 提及次數列為關鍵績效指標改變了銷售部門的焦點，將時間與資源改投入到監測網站點擊和社群媒體流量，從而產生許多永遠不會創造真正銷售的沒用之銷售線索。

儘管巨量資料分析非常擅長檢測相關性，尤其是小資料集可能會漏掉的細微相關性，但巨量資料分析不一定能找出因果關

係，或是有意義的相關性。例如，透過巨量資料分析可能發現，從 2006 年到 2011 年，美國各州的謀殺率跟 Internet Explorer 的市場率呈現高度相關，兩者均顯著地下降。但這並不意味著兩者之間有任何有意義的聯繫。資料分析師需要有正在嘗試用巨量資料來解決問題的企業知識。

巨量資料預測模型不一定能讓你更好地了解未來。在紐西蘭和澳大利亞經營發電和配電的 Meridian Energy Ltd. 就不再使用設備維護老化預測系統。該軟體本來可以預測公司所有大型設備的維護需求，包括發電機、風力渦輪機、變壓器、斷路器以及工業電池。然而，系統使用過時的建模技術，導致預測失敗。它使用不同的情境模擬，可以預測設備何時無法通過模擬測試。軟體所提出的建議無效，因為沒有準確地預測真實世界中哪個設備會停擺。最後 Meridian 將舊系統替換為 IBM 的維護和品質預測軟體，該軟體運用更多設備的即時資料來進行預測。

所有的資料集和資料導向的預測模型，都反映了人們選擇資料及執行分析的偏見。幾年前，Google 開發了它所謂的先進演算法，蒐集網站搜尋的資料來判斷有多少人得了流感與疾病如何傳播。它試圖計算在美國有多少人感染了流感，作法是將人們的位置與使用 Google 搜尋流感相關資訊進行關聯分析。與美國疾病管制中心 (CDC) 的數據相比，Google 持續高估流感感染率。科學家們認為，媒體當年廣泛報導流感疫情嚴重，並在社群媒體傳播的推波助瀾下被迷惑。該模型在預測流感趨勢時是基於錯誤的假設：透過 Google 搜尋流感相關資訊，為得到流感人數的精確指標。Google 的演算法只查看數字，而不管搜索結果的上下文。

除了敵對國家的選舉篡改之外，對上下文的關注不足和錯誤的假設，可能是導致多數政治專家錯誤預測 2016 年美國總統大選唐納・川普擊敗希拉瑞・柯林頓的主因。每一個主要的預測，都預言了柯林頓將擊敗川普，且獲勝的機率在 70% 至 99% 之間，但開票結果卻恰恰相反。

政治專家以及候選人的競選團隊對大量資料進行了分析。柯林頓將重點放在巨量資料分析，因為在歐巴馬 2008 年與 2012 年的勝利中，巨量資料分析扮演了關鍵角色。柯林頓的團隊加入了歐巴馬競選時所建立的資料庫，所蒐集的資料來自民意調查員和現場工作人員的報告、社交媒體貼文資料、線上行為以及用於預測消費者行為的資料。柯林頓小組認為，那些支持歐巴馬的選民將是他們的潛在支持者，並將焦點放在選民投票率很高的地區。但是，過去支持歐巴馬的關鍵者 (婦女、少數民族、大學畢業生和藍領工人) 並沒有如預期般都支持柯林頓。事實上，川普也轉向巨量資料分析，但更著重在針對選民群體而量身打造廣告訊息。

政治專家誤判柯林頓即將獲得勝利並非偶然，因為有些預測模型缺乏解釋潛在環境背景誤差的能力。民意調查、分析、詮釋也有問題，分析師更沒有花足夠的時間檢視用於預測模型的資料。許多選舉預測所使用的民意調查低估了川普的支持力量。州民意測驗不準確，也許是因為沒有把最初拒絕投給川普，但在最後一刻改變想法的共和黨人納入考量。威斯康辛州在選舉不久前的民意調查顯示，柯林頓遙遙領先川普。民意調查對選舉預測很重要，但它只是眾多參考資料

來源之一。預測模型無法確定誰會真的去投票。分析師忽視川普會在選場上挺身而出獲取勝利的訊號。英國在 2016 年 6 月投票決定是否脫歐時，也有類似的錯愕，民調預測與結果大相逕庭。

我們也不要忘了巨量資料分析引發的資安和隱私的問題。如同第 4 章所說，公司現在正積極地蒐集資料來分析人們的購物習慣、收入、嗜好、住所以及移動路徑 (透過行動裝置)。他們用巨量資料來探勘人們的事實資訊、透過細小的線索來將他們分群、將部分人標示為「高風險者」(例如貸款風險或是健康風險)、保護他們以及操弄他們以取得最大的利益。

當你將某人的個資結合其他不同來源的資料時，你就可以推論這個人的其他事實線索 (例如他們顯示出帕金森氏症的早期徵兆，或是無意識地受藍色或綠色產品吸引)。如果用問的，大部分的人們都不太願意揭露這些資訊，甚至是他們也不知道自己有這樣的情況。隱私專家擔憂在沒有法律程序的保護、缺乏反擊機制、甚至不知道自己已經被分類的情況下，人們將會蒙受其害。

資料來源：Linda Currey Post, "Big Data Helps UK National Health Service Lower Costs, Improve Treatments," *Forbes*, February 7, 2018; Michael Jude, "Data Preparation Is the Key to Big Data Success," *InfoWorld*, February 8, 2018; Rajkumar Venkatesan and Christina Black, "Using Big Data: 3 Reasons It Fails and 4 Ways to Make It Work," University of Virginia Darden School of Business Press Release, February 8, 3018; Ed Burns, "When Predictive Models Are Less Than Presidential," *Business Information*, February 2017; aron Timms, "Is Donald Trump's Surprise Win a Failure of Big Data? Not Really," *Fortune*, November 14, 2016; Steve Lohr and Natasha Singer, "The Data Said Clinton Would Win. Why You Shouldn't Have Believed It," *New York Times*, November 10, 2016; Nicole Laskowski and Niel Nikolaisen: "Seven Big Data Problems and How to Avoid Them," *TechTarget Inc.*, 2016; Joseph Stromberg, "Why Google Flu Trends Can't Track the Flu (Yet)," smithsonianmag.com, March 13, 2014; and Gary Marcus and Ernest Davis, "Eight (No, Nine!) Problems With Big Data," *New York Times*, April 6, 2014。

## 個案研究問題

1. 個案中所提到組織能從巨量資料分析中獲得哪些企業效益？
2. 找出個案中組織透過巨量資料分析而改善的兩個決策，以及沒有改善的兩個決策。
3. 說明使用巨量資料的限制。
4. 所有的組織都應該蒐集和分析巨量資料嗎？在公司決定要投入巨量資料分析前，必須先考量哪些管理、組織和科技的議題？